

LLM Long Context 优化总结（不完整版）



智 chu

在那以前要多想

关注他

📖 收录于 · 多模态模型推理优化 >

67 人赞同了该文章 >

引言

最近，业界在聚焦于 agent 开发，部门也开始在探索 Computer Use 相关的多模态模型和 Agent 应用。对于 computer use 场景来说，需要模型推理的上下文长度一般来说比较长，因此，涉及到一些大模型 long context 的优化，因此，本文大概的总结了一下当下的 Long Context 推理优化手段。

一般来说，Long Context 优化有两个核心目标：

1. **扩展支持长度**：使模型能够处理更长的上下文信息。
2. **提升推理效率**：在处理长上下文时，加快模型的推理速度。

目前，实现长上下文支持主要有以下技术路径：

首先，对于 256K tokens 以内的上下文长度，像 Qwen⁺ 和 Llama⁺ 等主流模型，通过标准的因果注意力机制（Causal Attention）即可应对。具体而言，即便模型的基础训练长度仅为 8K，也可以通过引入额外的长文本数据，并利用 RoPE（旋转位置编码）外推的方法进行监督微调（SFT），从而有效地将其上下文处理能力扩展至 256K（[RoPE 外推的缩放法则 —— 尝试外推 RoPE 至 1M 上下文](#)）。

其次，当上下文长度超过一定阈值（例如 256K 或更长）时，标准的因果注意力机制可能会遇到性能瓶颈。在这种情况下，为了保证模型效果，通常需要引入经过优化的非标准注意力机制来更好地处理超长序列。


具体方法


围绕上面两点，本文大概概括了一些目前 long context 技术

Attention 计算稀疏

在标准 LLM 的 transformers causal 计算中，输入序列中每个 token 需要和后面的 token 进行计算 attention，有一些工作通过对 attention mask 形状不同的探索，来达到计算稀疏的目的，如下图所示：

Bigbrid⁺:





MInference 1.0:

qwen2.5-1M 中注意力机制采用了下列技术




Figure 4: The three sparse methods in MInference.

Token Drop 方法⁺

H2O⁺

从注意力得分来看，大部分 token 是不重要的，少部分 token 比较重要，符合幂律分布，因此，可以利用这种稀疏性来优化 LLM 的内存占用和推理速度




Figure 2: (a) Attention Sparsity in pre-trained LLMs. (b) The distribution of accumulated attention scores with respect to the corresponding word (red scatter) and the co-occurrence times of words in the data (gray curve). The x-axis represents the word index in the vocabulary. (c) The performance comparison between the baseline model with full KV and the model w.o. heavy hitter. (d) Comparison between the baseline model with full KV, H2O with the local statistic, H2O with the global statistic, and the model with only the most important KV (Local). Apart from the baseline model, each model is evaluated with 20% KV cache budget.

KV Cache 保存数设置为 k :

(1) 前 k 个 token 正常计算注意力权重

(2) 对于第 $k+1$ 个 token: 计算 $k+1$ 个 k token 与每个 q token 的注意力权重之和，驱逐 $(k+1) - k = 1$ 个位置






Figure 1: Upper plots illustrate symbolic plots of an attention map deploying different KV cache policies in LLM generation. Lower right: contrasts their accuracy-memory trade-off. Left: the overview of H₂O framework.


StreamingLLM (ICLR 2024)



(d) StreamingLLM (ours)




SnapKV⁺ (NeurIPS 2024)



块级 KV Cache 计算

InfLLM



对于所有被驱逐的 tokens:

- (1) 从每个块中选出最具代表性的 r_k 个 token

For the m -th token, we define the representative score as:

$$r_m = \frac{1}{l_L} \sum_{j=1}^{l_L} \mathbf{q}_{m+j} \cdot \mathbf{k}_m,$$

知乎 @智chu

计算第 m 个 k token 和第 $m+1 \sim m+l_L$ (局部窗口大小) 个 q token 的注意力权重

- (2) 用每个单元代表性的 token 与当前 token 求相关性, 选出最相关的 k_m 个单元

We calculate the relevance score between $\mathbf{B}$ and current tokens $\mathbf{X}$ as:

$$\text{sim}(\mathbf{X}, \mathbf{B}) = \sum_{i=1}^{l_X} \sum_{j=1}^{r_k} \mathbf{q}_{i+l_P} \cdot \mathbf{k}_{b_j}^B.$$

知乎 @智chu

concat 初始 token + 上下文记忆的相关记忆 + 局部窗口 token

DeepSeek+ Native Sparse Attention

动态分层稀疏策略:


三路注意力融合

压缩路径 (compression): 将全文分为多个语义块 (如每块 512 字), 每个块通过可学习 MLP (具有可逆性) 压缩为 “摘要向量” — 粗涉全局理解


选择路径 (selection): 基于压缩路径的全局注意力分数, 筛选出 TOP-N 个关键块, 还原细粒度 token 信息 — 关键部分精读

滑动窗口路径 (sliding window): 对当前 token 的前后局部窗口进行全注意力计算 — 确保上下文连贯性


门控机制动态加权融合:



Kimi MoBA



MiniCPM4 InfLLM v2



KV Cache 存储吸收

标准的注意力计算如下：

$$attn = \frac{\text{softmax}(QK^T)}{\sqrt{d}} V$$

对于 GQA 形式的 Q、K、输入 x 之间的关系如下：

$$Q = x_i W_q$$

$$c_i = x_i W_c$$

$$K = c_i W_k$$

在不考虑 rope 的情况下，其中 QK 矩阵乘可等价为：

$$QK^T = (x_i W_q)(c_i W_k)^T = x_i (W_q W_k^T) c_i^T$$

根据该等式，可以看出可以将单独存储 K 矩阵转换为储存一个 C 向量，几乎成倍减少了 K cache 存储所花空间


但是，不巧的是在叠加 rope 操作后，中间的合并矩阵开始和位置差 t-i 相关，并不是一个定值，因此，导致无法仅用 C 向量来存储 K

$$QK^T = (x_i W_q R_t)(c_i W_k R_i)^T = x_i (W_q R_{t-i} W_k^T) c_i^T$$

因此，MLA 采用扩展 W_q 和 W_k 多增一部分 head 用来存储和 rope 有关信息，而原始头则不存储 rope 相关的位置信息，这样就妥协地解决了无法进行吸收的问题。

同时，由于这一部分增加 head，使得 LLM Prefill 计算事 attn 计算量有一定增长。但对于目前一些国产卡和 TPU（算力远大于带宽）来说，这一部分对于 LLM 整体减少的访存耗时还是远高于增加的算力损耗的。

Multi-Head Latent Attention (MLA)



KVCache 量化

待补充

所属专栏 · 2025-12-01 22:47 更新



多模态模型推理优化

智 chu

4 篇内容 · 469 赞同

订阅

最热内容 · 推理框架 (vllm和sglang) 对于qwen2.5 VL中ViT的优化

编辑于 2025-08-06 22:21 · 浙江

长上下文

大模型推理加速

注意力机制



日本 SGU 项目 37 所日本大学参与，相较于传统留学…

【概述：什么是 SGU 项目？】 [图片] 2008 年，日本为了推动本国大学与国际顶级院校的交流与合作，另外也为了提…

行知学园 SGU

100+热议 ×



理性发言，友善互动




还没有评论，发表第一个评论吧

推荐阅读

百面 LLM，综十三，
Preference Modeling:...

这篇 Blog 是我们沿着 Anthropic 一个重要观察而延展做的实验，这个实验结论和 Anthropic 的结论略有不同，其中这个观点可能能帮助我们理解 self-reward 背后的原理。本文考察了论文 "A General La... swthe... 发表于百面 LLM


LLM Agent 论文分享：将 RL
引入 LLM reasoning 的一种...

lafmdp

LLM 的本质：模型偏见和权重
的含义

akaih...

发表于 LLM(大 ...

HVO: LLM 多目标强化学习的高
效解决方案，打破多奖励的...

sonder